

AI 交易引擎：机器学习算法与场景应用（TASK 5）

作者：张鹏 • 日期：2026-07-18 • 工具：scikit-learn / TickFlow / pandas / matplotlib

任务要求

- 了解分类型机器学习算法，解释逻辑回归、决策树、随机森林等算法。
- 了解机器学习模型评价指标，解释混淆矩阵、AUC、ROC 等概念。
- Python 编程实现：加载分类数据（可用股票收益或 sklearn 乳腺癌数据集）；划分训练/测试集；构建并训练分类模型；计算 AUC；绘制 ROC 曲线。

目录

- 一、分类型机器学习算法解析（决策树 / 逻辑回归 / 随机森林 / SVM / GBDT）
- 二、模型评价指标解析（混淆矩阵 / ROC / AUC / Precision / Recall / F1）
- 三、Python 编程实现（一）癌症诊断二分类
- 四、Python 编程实现（二）股票次日涨跌预测（量化应用）
- 五、混淆矩阵 / ROC / AUC 深度解读
- 六、总结与应用心得

一、分类型机器学习算法解析

1.1 什么是"分类"

分类（Classification）是有监督学习中最常见的任务：给定一组带标签样本 (x, y) ，其中 y 取自离散集合（二分类时 $y \in \{0, 1\}$ ），学习一个函数 f 使得对于新样本能够输出正确的类别或类别概率。二分类是应用最广的形态：垃圾邮件识别、病理良恶性判断、信用违约预测、股票次日涨跌预测——本质都是“是 / 否”问题。

1.2 决策树（Decision Tree）

决策树用“一系列 if-else 判断”来做分类。训练时算法在每个节点上选择信息增益（ID3）、信息增益比（C4.5）或基尼不纯度（CART）最优的特征与阈值作为切分标准，把样本递归划分到两个子节点，直到叶节点足够纯。

- 优点：结果高度可解释（“若 $RSI < 30$ 且 5 日均线上穿 20 日均线，则判涨”），无需特征标准化，支持类别型与数值型特征混用。
- 缺点：单棵深树容易过拟合，对样本微小扰动敏感；边界呈阶梯状，无法平滑刻画连续关系。

1.3 逻辑回归（Logistic Regression, LR）

虽名“回归”，实为线性二分类器。先做线性组合 $z = w \cdot x + b$ ，再通过 Sigmoid 函数 $\sigma(z) = 1/(1 + e^{-z})$ 将结果压缩到 $[0, 1]$ 作为正类概率。训练时最大化对数似然（等价于最小化交叉熵），通常配合 L1/L2 正则防止过拟合。

- 优点：训练与预测极快，参数具有可读的对数几率解释（每个特征系数 = 变动一个单位使 log-odds 增加多少），是量化、风控中最常见的基线模型。
- 缺点：只能拟合线性决策边界；对特征间非线性交互不敏感，需人工构造交互项或多项式特征。

1.4 随机森林（Random Forest, RF）

Bagging 思想的经典代表：在训练集上做有放回抽样生成多个子样本，每棵树在每个分裂节点上还从随机的特征子集中挑最优特征，最终由若干棵去相关的决策树投票。

- 优点：几乎自动抗过拟；能捕获非线性交互；带自然的特征重要性输出；对异常值、缺失值容忍度高。
- 缺点：模型体积大、推理慢；对训练集范围外的数据外推能力弱；难像单棵树那样人肉解释。

1.5 支持向量机（SVM）

SVM 寻找一个把两类样本分开且间隔最大的超平面；通过核函数（如 RBF、多项式）可以在隐式的高维空间中处理非线性问题。

- 优点：小样本高维数据表现好；决策边界几何直观。
- 缺点：核函数、C、 γ 参数敏感；训练复杂度约为 $O(n^2)$ ，大样本很慢；概率输出需额外 Platt Scaling。

1.6 梯度提升树（GBDT）

Boosting 家族：每棵新树拟合前一轮预测的残差（负梯度方向），逐步叠加得到强分类器。XGBoost、LightGBM、CatBoost 都属于这一家族，是 Kaggle 与量化领域的常胜将军。

- 优点：单模型精度高；较简单的特征工程即可达到不错效果；能给出特征重要性。
- 缺点：训练串行不好并行；超参较多；样本外调优要小心过拟合。

1.7 算法对比一览

算法	类别	典型场景	可解释性	是否需标准化
决策树	规则/树	规则挖掘、初步分析	★★★★★	否
逻辑回归 LR	线性	风控评分卡、基线模型	★★★★★	建议
随机森林 RF	集成/Bagging	特征多、非线性交互复杂	★★★	否
支持向量机 SVM	核方法	小样本高维（文本、生信）	★★	是
梯度提升 GBDT	集成/Boosting	结构化数据主流首选	★★★	否

二、模型评价指标解析

2.1 混淆矩阵（Confusion Matrix）

混淆矩阵把预测结果与真实结果按 2×2 方阵组织，是所有二分类指标的“母体”。

	预测为正（1）	预测为负（0）
实际为正（1）	TP 真正例	FN 假负例（漏报）
实际为负（0）	FP 假正例（误报）	TN 真负例

由此派生的核心指标：

- 准确率 $Accuracy = (TP + TN) / \text{总数}$ —— 整体命中率；类别不均衡时会失真。
- 精确率 $Precision = TP / (TP + FP)$ —— “预测为正的样本里真正的比例”；量化下预测涨的股票里真涨的比例。
- 召回率 $Recall$ （灵敏度） $= TP / (TP + FN)$ —— “真正的样本被抓到的比例”；医学中的漏诊率互补指标。
- $F1 = 2 \cdot P \cdot R / (P + R)$ —— 精确率与召回率的调和平均，兼顾两者。

- 特异度 $\text{Specificity} = \text{TN} / (\text{TN} + \text{FP})$ —— 反面指标，衡量正确排除非正样本的能力。

2.2 ROC 曲线 (Receiver Operating Characteristic)

ROC 曲线以 $\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$ 为横轴、 $\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$ 为纵轴，随着判定阈值从 1 逐步下降到 0，模型在每个阈值下取一个 (FPR, TPR) 点，把这些点连成的曲线就是 ROC 曲线。

- 左上角 (0, 1)：完美分类器；
- 对角线 $y = x$ ：等价于抛硬币的瞎猜；
- ROC 曲线越靠左上，模型区分正负类的能力越强。

2.3 AUC (Area Under the ROC Curve)

AUC 是 ROC 曲线下的面积，直观意义是：随机取一个正样本与一个负样本，模型给正样本的分数高于负样本的概率。

- $\text{AUC} = 0.5$ ：模型没有区分能力，等于瞎猜；
- $\text{AUC} = 1.0$ ：完美分类；
- 业务经验： $\text{AUC} > 0.8$ 一般算“强”， $0.7 - 0.8$ 是“可用”， $0.6 - 0.7$ 是“弱”，接近 0.5 意味着基本无效。

为什么金融场景偏爱 AUC 而不是 Accuracy？在类别不均衡（如信用违约、股价异常）场景，accuracy 会被多数类拖着走，只要预测全为多数类就能得到很高的 accuracy 却毫无信息量。AUC 是排序质量指标，只要模型能把正样本排在负样本之前就获得高分，与阈值选择无关，这对判断“信号是否有价值”至关重要。

三、Python 编程实现（一）癌症诊断二分类

3.1 数据概览

- 数据集：`sklearn.datasets.load_breast_cancer`（UCI 威斯康星乳腺癌）
- 样本数：569
- 特征数：30 个数值特征（细胞核几何/纹理统计量：半径、周长、光滑度、凹陷度等）
- 标签：良性(1) 357 例，恶性(0) 212 例
- 划分：70% 训练 / 30% 测试，分层抽样，特征标准化 (StandardScaler)

3.2 核心代码

```
# ① 加载数据
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.svm import SVC
from sklearn.metrics import confusion_matrix, roc_curve, auc

data = load_breast_cancer()

# ② 训练/测试集划分 + 标准化
X_train, X_test, y_train, y_test = train_test_split(
    data.data, data.target, test_size=0.3, stratify=data.target, random_state=42)
scaler = StandardScaler()
```

```
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# ③ 构建并训练分类模型
models = {
    'LR': LogisticRegression(max_iter=2000, random_state=42),
    'RF': RandomForestClassifier(n_estimators=200, random_state=42),
    'SVM': SVC(kernel='rbf', probability=True, random_state=42),
    'GBDT': GradientBoostingClassifier(random_state=42),
}
for name, clf in models.items():
    clf.fit(X_train, y_train)
    # ④ 评估 + 计算 AUC
    y_proba = clf.predict_proba(X_test)[:, 1]
    fpr, tpr, _ = roc_curve(y_test, y_proba)
    print(name, 'AUC =', round(auc(fpr, tpr), 4))
```

3.3 结果分析

表 3-1 癌症数据集 4 模型评估结果（测试集 171 例）

模型	准确率	精确率	召回率	F1	AUC	TN / FP / FN / TP
逻辑回归 LR	0.9883	0.9907	0.9907	0.9907	0.9981	63 / 1 / 1 / 106
支持向量机 SVM	0.9766	0.9813	0.9813	0.9813	0.9978	62 / 2 / 2 / 105
随机森林 RF	0.9415	0.9450	0.9626	0.9537	0.9923	58 / 6 / 4 / 103
梯度提升 GBDT	0.9415	0.9369	0.9720	0.9541	0.9898	57 / 7 / 3 / 104




图 3-1 癌症二分类——四个模型混淆矩阵对比

解读：LR 的 FN=1、FP=1，仅 2 个错分，堪称临床可用水平；RF/GBDT 稍逊但 FN 仍然很低（3 - 4），符合医学“宁可误诊、不可漏诊”的偏好。SVM 位居中间。




图 3-2 癌症二分类——四个模型 ROC 曲线对比

解读：四条 ROC 曲线全部紧贴左上角，AUC 均在 0.99 以上，说明特征信噪比极高。LR 与 SVM 几乎重合并达到顶点 ($AUC \approx 0.998$)；RF/GBDT 略低但差距微小。




图 3-3 癌症二分类——各模型评估指标横向对比

解读：所有指标 (Accuracy/Precision/Recall/F1/AUC) 在四个模型上均 ≥ 0.94 。LR 反而是最优——数据线性可分时，简单模型胜过复杂模型，这是“奥卡姆剃刀”在机器学习中的经典体现。

核心结论 A：医学诊断数据“太干净”

30 个专家精心构造的形态学特征让 4 个模型的 AUC 都 ≥ 0.99 ，问题本身几乎线性可分。这既说明特征工程的价值，也提醒我们不要盲目相信“复杂 = 更好”。

四、Python 编程实现（二）股票次日涨跌预测（量化应用）

4.1 数据来源

通过 TickFlow SDK 拉取 A 股 4 只行业代表股（新能源车、电池、白酒、金融）的近约 1200 交易日日 K 线：

代码	名称	行业	样本量
002594.SZ	比亚迪	新能源汽车	1180
300750.SZ	宁德时代	动力电池	1180
600519.SH	贵州茅台	高端白酒	1180
601318.SH	中国平安	综合金融	1180

合并后共 4720 条 有效样本（涨 2188 / 跌 2532）。

4.2 特征工程（共 15 个技术特征）

类别	特征	含义
收益率	ret_1 / ret_2 / ret_5 / ret_10	1/2/5/10 日收益率
均线偏离	ma_diff_5_20 / ma_diff_10_20	短均线相对长均线的相对偏离度
波动率	vol_5 / vol_20	5/20 日收益率的滚动标准差
量能	vol_ratio, vol_chg_1	量比 / 成交量日变化率
技术指标	rsi_14, macd, macd_s, macd_h, amp_pct	RSI、MACD 系列、日内振幅

标签：次日收盘价 > 今日收盘价 ⇒ 1（涨），否则 0。

4.3 核心代码

```
# ① 加载 4 只股票数据并合并
STOCKS = ['002594.SZ', '300750.SZ', '600519.SH', '601318.SH']
all_feats = []
for code in STOCKS:
    df = pd.read_csv(f'data/{code.replace(".", "_")}.csv')
    fe, feature_cols = build_features(df) # 计算 15 个技术特征 + 标签
    all_feats.append(fe)
data = pd.concat(all_feats, ignore_index=True)

# ② 划分与标准化
X_train, X_test, y_train, y_test = train_test_split(
    data[feature_cols], data['label'], test_size=0.3, stratify=data['label'], random_state=42)
X_train = StandardScaler().fit_transform(X_train)

# ③ 构建 4 个模型 → ④ 评估 AUC → ⑤ 绘制 ROC
models = {
    'LR': LogisticRegression(max_iter=3000, random_state=42),
    'RF': RandomForestClassifier(n_estimators=300, max_depth=6, random_state=42),
    'SVM': SVC(kernel='rbf', probability=True, random_state=42),
    'GBDT': GradientBoostingClassifier(n_estimators=200, max_depth=3,
                                       learning_rate=0.05, random_state=42),
}
for name, clf in models.items():
```

```
clf.fit(X_train, y_train)
y_proba = clf.predict_proba(X_test)[: , 1]
fpr, tpr, _ = roc_curve(y_test, y_proba)
print(name, 'AUC =', round(auc(fpr, tpr), 4))
```

4.4 结果分析

表 4-1 股票次日涨跌预测——四模型评估结果（测试集 1416 例）

模型	准确率	精确率	召回率	F1	AUC
逻辑回归 LR	0.5438	0.5309	0.1311	0.2103	0.5208
随机森林 RF	0.5360	0.4975	0.1509	0.2316	0.5230
支持向量机 SVM	0.5304	0.4727	0.1189	0.1900	0.5354
梯度提升 GBDT	0.5261	0.4784	0.2530	0.3310	0.5031




图 4-1 股票次日涨跌预测——四个模型混淆矩阵对比

解读：LR/SVM 的策略明显是“保守派”——大量样本被判为跌，只有极少数（86/78）被判涨；GBDT 反之更“激进”（判涨 347 次）。但无论保守还是激进，正判率都仅在 50% 左右，说明模型没有捕捉到可靠的方向性信号。




图 4-2 股票次日涨跌预测——四个模型 ROC 曲线对比

解读：四条 ROC 曲线都紧贴对角线，AUC 集中在 0.50 — 0.54。与图 3-2 形成鲜明对照——金融市场的“技术分析”信号极其微弱，这正是有效市场假说的实证体现。




图 4-3 股票次日涨跌预测——各模型评估指标横向对比

解读：不同模型的精确率和召回率之间存在明显“跷跷板”——LR/SVM Precision 较高但 Recall 极低 ($\leq 13\%$)，GBDT 相反。这体现了阈值选择的取舍：谨慎则漏机会，激进则多误判，没有“免费的午餐”。




图 4-4 股票预测——随机森林特征重要性排序

解读：波动率类特征（vol_20，vol_5）与量能类特征（vol_ratio） 排在前列，高于均线偏离与 MACD。这提示“波动放大 + 成交异动”比“价格趋势”含有更多短期信息——但即便是最重要的特征，其单个重要性也不超过 0.10，反映信号总体分散且弱。

核心结论 B：股票次日涨跌几乎不可预测
四个主流算法在 15 个常用技术指标上的 AUC 集中于 0.51 — 0.54，与瞎猜相差无几。这恰好是本次实验最有价值的教学结果：机器学习不是量化的“银弹”，能否赚钱取决于特征信噪比而非模型精巧程度。

五、混淆矩阵 / ROC / AUC 深度解读

5.1 混淆矩阵在交易场景下的经济学含义

单元格	意义	交易场景
TP 真正例	预测涨且真涨	成功买入，盈利
FP 假正例	预测涨但真跌	错买了跌股， 亏损
TN 真负例	预测跌且真跌	正确规避，未参与
FN 假负例	预测跌但真涨	错过机会，机会成本

- 交易者最痛恨 FP（真金白银亏）→ 关注 Precision；提高信号阈值可提升 Precision，但会牺牲 Recall。
- 医生最痛恨 FN（漏诊）→ 关注 Recall。领域不同，评价指标就要跟着换。

5.2 ROC 曲线的关键性质

- ROC 曲线是“阈值扫描图”：对每一个阈值 t ，把 $\text{proba} \geq t$ 视为正类，产生 (FPR, TPR)，连成曲线。
- ROC 与阈值无关：改变阈值只改变在曲线上的工作点，不改变曲线本身。

- ROC 与类别不均衡不敏感：即便正负比例 1:99，ROC 曲线依然可信；这一点 accuracy 不具备。

5.3 AUC 使用中的常见误区

- AUC 高 ≠ 一定赚钱：交易还有滑点、手续费、容量、冲击成本。AUC 0.55 的模型如果换手过高，交易成本可能吃掉全部 alpha。
- AUC 只衡量排序质量：不代表概率校准（predict_proba = 0.6 未必真有 60% 的正例概率）。
- 样本外 AUC 才是真 AUC：训练集 AUC 高、测试集 AUC 低 = 过拟合，是量化开发中最常见的陷阱。
- 不同任务的 AUC 不能直接比较：癌症的 AUC 0.99 与股价的 AUC 0.55 不能放在一起衡量“哪个模型更好”，任务难度天差地别。

六、总结与应用心得

6.1 医学 vs 金融：一个绝妙的对照

维度	癌症诊断	股票预测
特征质量	30 个专家精心设计的高信噪比特征	15 个技术指标，噪声远大于信号
样本规模	569	4720
AUC	0.99+	0.51 - 0.54
胜率来源	疾病是客观物理事实	价格是博弈结果，反身性强
最优模型	逻辑回归（线性即可）	无显著差异（都很弱）
可否直接实盘	达临床可用水平	直接下单必亏（含手续费）

6.2 机器学习在量化交易中的正确姿势

1. 信号强度先于模型复杂度：AUC 0.52 换任何算法仍是 0.52，问题在特征而非模型。真正的 alpha 常来自另类数据（分析师情绪、供应链、订单流、卫星图像）。
2. 严格时序切分：实盘必须走 WalkForward 或 PurgedKFold，避免“未来函数”泄漏。本报告随机分层切分只用于教学演示。
3. 合理的评估指标：不仅看 AUC，还要看信号稳定性、换手率、扣费后收益、最大回撤等。分类精度只是万里长征第一步。
4. 组合胜过单预测：即使单预测 AUC 仅 0.53，通过横截面选股（每天挑分数 top-N），叠加交易次数，组合 Sharpe 也能显著改善。
5. 敬畏市场：类似癌症数据的高 AUC 在金融领域几乎不可能。看到宣称 AUC 0.95 的股票预测策略，先怀疑数据泄漏。

6.3 本次任务核心收获

- 算法侧：LR / RF / SVM / GBDT 四种主流分类器的适用场景与优缺点。
- 评估侧：混淆矩阵 → Precision / Recall / F1, ROC → AUC，各自解决什么问题。
- 量化视角：机器学习不是量化的“银弹”，特征工程与市场理解才是核心竞争力。
- 工程侧：sklearn 的标准化流水线——fit → predict → predict_proba → 评估——可以在任何二分类任务上复用。

— TASK 5 报告完 | 数据来源: sklearn / TickFlow | 作者: 张鹏 —